

Sprint 3


TI-VI / Grupo 07 / Alzheimer MRI

João Vítor de Freitas
Nagib Alexandre
Vitor Militão
Vitória Símil
Yasmin Cassemiro

Contextualização:

O nosso objetivo é projetar uma aplicação capaz de classificar uma ressonância magnética cerebral a fim de classificar o estágio de Alzheimer do paciente, desde não ocorrência, até o estágio grave. Seguindo um dos 17 ODS da Organização das Nações Unidas.

Pretendemos contribuir com uma identificação rápida e acessível dessa doença, principalmente nos estágios iniciais. Facilitando qualquer tratamento posterior.



3 SAÚDE E
BEM-ESTAR



Literaturas:

- <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/a/alzheimer>
- <https://www.alzint.org/about/dementia-facts-figures/dementia-statistics>
- A. W. Salehi, P. Baglat, B. B. Sharma, G. Gupta and A. Upadhy, "A CNN Model: Earlier Diagnosis and Classification of Alzheimer Disease using MRI," 2020 International Conference on Smart Electronics and Communication (ICOSEC), Trichy, India, 2020
- Multi-classification of alzheimer disease on magnetic resonance images (MRI) using deep convolutional neural network (DCNN) approaches, Sunday Adeola Ajagbe , Kamorudeen A. Amuda2 , Matthew A. Oladipupo3 , Oluwaseyi F. AFE4 and Kikelomo I. Okesola4



Atualizações:

Processamento e Análise de Imagens.

Atualizações:


Processamento e Análise de Imagens

Implementamos uma CNN (Convolutional Neural Network) baseada na arquitetura ResNet18 pré-treinada. De forma a reutilizar as camadas convolucionais já treinadas no ImageNet, facilitando a identificação de padrões genéricos.

Inicialmente, somente a camada final é treinada (warmup), enquanto o restante permanece congelado. Evitando ajustes prematuros de pesos e acelerando a convergência.

Em seguida, as camadas mais profundas são liberadas para fine-tuning, permitindo que o modelo se adapte ao domínio específico das imagens.

No modelo atual, utilizamos 5 eras de warmup e 5 eras de fine-tuning.



Atualizações:

Processamento e Análise de Imagens



O processo começa com a distribuição das imagens (originais e aumentadas) em:

70% treino / 15% validação / 15% teste

Equilibrando a distribuição de cada nível de Alzheimer

Realizamos um pré processamento padronizado, redimensionando para o tamanho aceito pela rede, conversão para tensor e normalização para alinhar a distribuição dos pixels com aquela usada no treinamento da ResNet.

Aplicamos transformações leves como espelhamento e rotações para aumentar a variabilidade dos dados.

Atualizações:

Processamento e Análise de Imagens

Obtivemos os seguintes resultados:

Acurácia (Accuracy): 97,38%

Precisão (Precision): 97,66%

Sensibilidade (Recall): 97,74%


F1-Score: 97,70%

Especificidade: 99,07%

Taxa de Falsos Positivos (FPR): 0,93%

Taxa de Falsos Negativos (FNR): 2,26%

Tempo de execução: $\approx$ 54 minutos



Atualizações:

Computação Distribuída

Atualizações:


Computação Distribuída

O treinamento foi estruturado utilizando aprendizado federado, via biblioteca *Flower*. Em vez de concentrar os dados em um único servidor, cada cliente treina localmente sua cópia da CNN com as imagens que possuir e envia somente os pesos atualizados do modelo.

O servidor por sua vez, agrega os parâmetros recebidos e atualiza o modelo global, repetindo o processo de forma iterativa.

Essa organização distribuída permite que o aprendizado seja colaborativo entre diferentes fontes de dados, mantendo a privacidade e evitando o custo de transferir grandes volumes de imagem.

Trazendo um treinamento escalável e permitindo uma evolução descentralizada.



Atualizações:

Computação Distribuída

Conclusões momentâneas:

- Tempo total global de teste com 3 clientes: 2545.44s (~42 min)
- Tempo médio por rodada: 0.33s
- **Sobre o desempenho:** O modelo centralizado atinge 97.38%, enquanto o federado ficou em ~90.5%
- **Privacidade e escalabilidade:**
 - Protege dados sensíveis dos pacientes.
 - Permite treinar em diferentes hospitais ou dispositivos locais, sem enviar dados brutos.
 - Pode melhorar continuamente conforme mais clientes participam

Categoria	Cliente 1	Cliente 2	Cliente 3
Acurácia Local de Treino	63.46	63.47	63.48
Acurácia Global (Validação Distribuída)	89.99	89.100	89.101
Acurácia Final (Teste Independente)	90.53	90.54	90.55
Loss Global	0.2601	0.2602	0.2603
Precisão (Precision)	91.60	91.61	91.62
Recall / Sensibilidade	91.68	91.69	91.70
F1-Score	91.64	91.65	91.66
Especificidade	96.56	96.57	96.58
FPR (False Positive Rate)	3.44	3.45	3.46
FNR (False Negative Rate)	8.32	8.33	8.34
Tempo Total por Cliente	2397.44	2397.45	2397.46

Cronograma:

O que resta ser feito

Cronograma:

Sprint 3

Computação Paralela

Aplicação do Federated Learning para paralelização dos clientes.

(Paralelismo de dados)

Visual

Implementação de uma interface gráfica interativa.

(Envio de imagens)

Estrutural

Revisão geral para possíveis ajustes, dado quaisquer contratempos.

(Refinamento)

Conclusões:

Intermediárias

A partir da implementação da rede neural convolucional (CNN) combinada com a abordagem de Computação Distribuída via Federated Learning, foi possível alcançar excelentes resultados, especialmente na identificação do Alzheimer em estágios iniciais

Os próximos passos serão fundamentais para reduzir o tempo de execução do treinamento, explorando técnicas de Computação Paralela e otimizando o desempenho do processamento distribuído

Garantir que o aumento da eficiência não comprometa a qualidade e a precisão da aplicação

Obrigado!

